

Estimadores de máxima verosimilitud: distribución conjunta de la muestra

- Los conceptos de funciones de verosimilitud se deben a Fisher, y es fundamental en inferencia estadística.
- Este concepto se define a partir de la distribución conjunta de la muestra.
- Supongamos una variable discreta x con distribución $P(x; \vartheta)$ que es conocida.
- Supongamos que tomamos muestras independientes de tamaño n , representando está por el vector \mathbf{X} .
- Así podemos definir la distribución conjunta de la muestra en función de esta variable, y para el caso de una muestra aleatoria simple tenemos:
 - $P(\mathbf{X} = \mathbf{X}_0) = P(x_1 = x_{10}, x_2 = x_{20}, \dots, x_n = x_{n0}) = P(x_{10}) \dots P(x_{n0})$
- Así conociendo la distribución $P(x; \vartheta)$ podemos calcular fácilmente la probabilidad de cualquier muestra (**ver ejemplo 7.6**, para una Poisson, $P(x; \lambda)$, **7.7 para una binomial** y **7.8 para una exponencial**).

Estimadores de máxima verosimilitud: distribución conjunta de la muestra

- En el **caso continuo** (función de densidad $f(x; \vartheta)$), la probabilidad del intervalo $x_i - 1/2, x_i + 1/2$, la podemos aproximar por el rectángulo de altura $f(x_i)$ y base unidad:
 - $P(x_i) = f(x_i) \cdot 1$
- Por tanto la probabilidad de la muestra aleatoria simple:
 - $P(x_1, \dots, x_n) = \prod f(x_i)$
- Así la función de densidad conjunta de la muestra $f(x_1, \dots, x_n)$ se interpreta como la probabilidad de obtener los valores muestrales $x_1 \pm 0,5, \dots, x_n \pm 0,5$.

Estimadores de máxima verosimilitud: la función de verosimilitud

- Sea una variable aleatoria continua x con función de densidad que $f(x | \vartheta)$ para indicar que depende de un vector de parámetros ϑ . Es decir dado que conozco ϑ , representa cual es la función de densidad de la variable aleatoria x .
- Si tenemos una muestra aleatoria simple $\mathbf{X} = (x_1, \dots, x_n)$, entonces la función de densidad conjunta de la muestra es:
 - $f(\mathbf{X} | \vartheta) = \prod f(x_i | \vartheta)$
- Es decir cuando conozco ϑ la expresión anterior determina la probabilidad de aparición de cada muestra.



Estimadores de máxima verosimilitud: la función de verosimilitud

- En inferencia para un problema de estimación se **conoce un valor particular de una muestra X** , siendo **desconocido el parámetro ϑ** .
- Así si sustituimos X por el valor observado de una muestra, $X_0 = (x_{10}, \dots, x_{n0})$, entonces la función $f(X_0 | \vartheta)$ puede ser vista como una función del parámetro.
- Es decir $f(X_0 | \vartheta)$ puede ser visto y proporciona, para cada valor de ϑ , la probabilidad de obtener el valor muestral X_0 para ese valor del parámetro ϑ .

Estimadores de máxima verosimilitud: la función de verosimilitud

- Así esta nueva función que obtenemos cuando variamos ϑ , mientras mantenemos \mathbf{X}_0 fijo (no variamos la muestra), define la **función de verosimilitud**, $\ell(\vartheta | \mathbf{X})$ (dado que conozco la muestra, entonces como varia la probabilidad en función del parámetro ϑ):
 - $\ell(\vartheta | \mathbf{X})$, o $\ell(\vartheta)$: Es decir $\ell(\vartheta | \mathbf{X}) = \ell(\vartheta) = f(\mathbf{X}_0 | \vartheta)$, con \mathbf{X}_0 fijo y ϑ variable.
- La óptica cambia, en vez de tener un parámetro fijo ϑ y calcular para ese parámetro la probabilidad de obtener distintas muestras \mathbf{X} , lo que fijamos es una determinada muestra \mathbf{X}_0 y estimamos que valor del parámetro ϑ hace más verosímil la muestra que se observa \mathbf{X}_0 .

Estimadores de máxima verosimilitud: la función de verosimilitud



Estimadores de máxima verosimilitud: la función de verosimilitud

- Este enfoque cambia completamente la forma de la función y ya no se parece en nada a la densidad o distribución de probabilidad, aunque sigue teniendo unidades de probabilidad (pensar porque tiene unidades de probabilidad).
- Si tenemos una variable x que distribuye según una Poisson:
 - $P(x = r) = \frac{\lambda^r}{r!} e^{-\lambda}, r = 0, 1, 2, \dots$, y observamos el valor de la muestra $x=5$, entonces $\ell(\lambda) = \frac{\lambda^5}{5!} e^{-\lambda}$, es la función de verosimilitud para una muestra de un solo valor de $x=5$.

Estimadores de máxima verosimilitud: la función de verosimilitud

- Esta función $\ell(\lambda)$ es continua en λ y **proporcional a la probabilidad de observar $\mathbf{x}=5$ para cada valor posible de λ .**
- El valor de la verosimilitud no es único: $\ell(\vartheta_1) = f(\mathbf{X}_0|\vartheta_1) > f(\mathbf{X}_0|\vartheta_2) = \ell(\vartheta_2)$.
- Esto quiere decir que **a la vista de los datos muestrales el valor del parámetro ϑ_1 es más verosímil** que el valor del parámetro ϑ_2 ya que la probabilidad de obtener la muestra observada \mathbf{X}_0 es mayor con ϑ_1 que con ϑ_2 .

Estimadores de máxima verosimilitud: la función de verosimilitud

- Observar que la verosimilitud tiene unidades, las de la variable x , entonces la diferencia de verosimilitudes no tiene sentido ya que varía arbitrariamente en función de las unidades de la variable x .
- Por lo tanto para comparar verosimilitudes lo mejor es el cociente de las mismas ya que este es invariante frente a las diferentes unidades de la variable:
 - $\ell(\vartheta_1 | \mathbf{X})/\ell(\vartheta_2 | \mathbf{X})$, este cociente es invariante hacia cambios de escalas en la variable x que se está observando.
 - El cociente $\ell(\vartheta_1)/\ell(\vartheta_2)$ se puede sustituir por la diferencia de logaritmos: $\ln\ell(\vartheta_1) - \ln\ell(\vartheta_2)$.
- Así se puede definir la **función soporte** por el logaritmo de la verosimilitud: $L(\vartheta) = \ln\ell(\vartheta)$.

Estimadores de máxima verosimilitud: la función de verosimilitud

- Se define como la discriminación contenida en la muestra \mathbf{X} entre ϑ_1 y ϑ_2 a la siguiente expresión (diferencia de soporte de ambos valores):
$$L(\vartheta_2) - L(\vartheta_1) = \ln \ell(\vartheta_2) - \ln \ell(\vartheta_1).$$
- Si ϑ es un parámetro cuyos valores posibles pertenecen a un intervalo ϑ_1 y ϑ_2 , llamaremos **discriminación relativa** entre ϑ_2 y ϑ_1 a:
 - $(L(\vartheta_2) - L(\vartheta_1))/(\vartheta_2 - \vartheta_1) = (\ln \ell(\vartheta_2) - \ln \ell(\vartheta_1))/(\vartheta_2 - \vartheta_1).$
- En el limite cuando $\vartheta_2 \rightarrow \vartheta_1$ obtenemos la tasa de discriminación para la muestra \mathbf{X} respecto el parámetro ϑ valorada en el punto ϑ_1
- $$d(\vartheta_1) = \lim_{\vartheta_2 \rightarrow \vartheta_1} \frac{L(\vartheta_2) - L(\vartheta_1)}{\vartheta_2 - \vartheta_1} = \lim_{h \rightarrow 0} \frac{L(\vartheta_1 + h) - L(\vartheta_1)}{h} = \left. \frac{dL(\vartheta)}{d\vartheta} \right|_{\vartheta = \vartheta_1},$$
 fue introducida por Fisher, que la denominó “Score”.

Estimadores de máxima verosimilitud: la función de verosimilitud

- Si este “score” cumple que $d(\vartheta_1) > 0$, la verosimilitud aumenta para valores superiores a ϑ_1 ,
 - es decir, la muestra tiene mayor probabilidad de ocurrir con valores mayores que ϑ_1 ,
- Mientras que si $d(\vartheta_1) < 0$ el razonamiento es el contrario, la verosimilitud aumenta para valores inferiores de ϑ_1 ,
 - es decir, la muestra tiene mayor probabilidad de ocurrir con valores menores que ϑ_1 .

Estimadores de máxima verosimilitud: la función de verosimilitud

➤ Resumiendo:

1. La función de verosimilitud es la herramienta básica que nos permite juzgar la compatibilidad entre los valores muestrales observados y los posibles valores del parámetro de la distribución de probabilidad.
2. Si queremos comparar dos posibles valores del parámetro, ϑ , se debe utilizar el cociente de sus verosimilitudes, y no su diferencia, ya que la diferencia depende de la escala de medida de las variables, como hemos dicho antes.

Estimadores de máxima verosimilitud: la función de verosimilitud

- Por ejemplo para estimar el parámetro, λ , de Poisson de la muestra observada x_1, \dots, x_n hacemos:
 - $P(x) = \frac{\lambda^x}{x!} e^{-\lambda}$, distribución de Poisson.
 - $\ell(\lambda) = \prod P(x_i | \lambda) = P(x_1 | \lambda) P(x_2 | \lambda) \dots P(x_n | \lambda) = \frac{\lambda^{\sum x_i}}{\prod x_i!} e^{-n\lambda}$
- Como el término $1/(\prod x_i!)$ es una constante la podemos eliminar y escribir la función de verosimilitud para la distribución de Poisson como:
 - $\ell(\lambda) = e^{-n\lambda} \lambda^{\sum x_i} = e^{-n\lambda} \lambda^{n\bar{x}}$
 - Así la función soporte será para la distribución de Poisson vendrá dada por:
 $L(\lambda) = -n\lambda + n\bar{x} \ln \lambda$ (mirar los ejercicios para el resto de distribuciones).

Estimadores de máxima verosimilitud: el método de máxima verosimilitud

- Una vez que tenemos calculada una función de verosimilitud para un vector de parámetros $\boldsymbol{\vartheta}$, $\ell(\boldsymbol{\vartheta})$, un procedimiento intuitivo para estimar los parámetros de la distribución a partir de los valores observados muestralmente es maximizar el valor del parámetro que sea más verosímil, es decir el que maximice la verosimilitud.
- Así podemos resolver el sistema de ecuaciones:
 - $\partial \ell(\boldsymbol{\vartheta}) / \partial \vartheta_1 = 0, \dots, \partial \ell(\boldsymbol{\vartheta}) / \partial \vartheta_p = 0$
- El valor que resuelve el sistema de ecuaciones, $\hat{\boldsymbol{\vartheta}}$, corresponderá a un máximo si el valor de la matriz hessiana de segundas derivadas en ese punto es definida negativa: $H(\hat{\boldsymbol{\vartheta}}) = (\partial^2 \ell(\boldsymbol{\vartheta}) / \partial \vartheta_i \partial \vartheta_j)_{\boldsymbol{\vartheta} = \hat{\boldsymbol{\vartheta}}}$.

Estimadores de máxima verosimilitud: el método de máxima verosimilitud

- A la hora de hacer los cálculos de estimadores máximo-verosímiles (MV) se obtienen derivando la función soporte: $L(\vartheta) = \ln \ell(\vartheta)$, ya que la transformación logarítmica es monótona y por tanto tiene el mismo máximo.
- Recordemos que la derivada de la función soporte la habíamos definido como la tasa de discriminación: $d(\vartheta_1) = \lim_{\vartheta_2 \rightarrow \vartheta_1} \frac{L(\vartheta_2) - L(\vartheta_1)}{\vartheta_2 - \vartheta_1} = \left. \frac{dL(\vartheta)}{d\vartheta} \right|_{\vartheta = \vartheta_1}$, así podemos definir el estimador máximo-verosímil como aquel valor de los parámetros para los que se anulan la tasa de discriminación de la muestra.

Estimadores de máxima verosimilitud: Ejemplo

- Para estimar los parámetros de una normal de la muestra observada x_1, \dots, x_n :
 - $f(x) = 1/\sigma(2\pi)^{0.5} \exp\{-(1/2\sigma^2)(x-\mu)^2\}$, densidad de probabilidad normal.
 - $\ell(\mu, \sigma^2) = \prod f(x_i | \mu, \sigma^2) = f(x_1 | \mu, \sigma^2) f(x_2 | \mu, \sigma^2) \dots f(x_n | \mu, \sigma^2) =$
 $\prod_i (1/\sigma(2\pi)^{0.5}) \exp\{-(1/2\sigma^2)(x_i - \mu)^2\} =$
 $(1/(\sigma(2\pi)^{0.5})^n) \exp\{-(1/2\sigma^2)\sum (x_i - \mu)^2\}.$
- Así la función soporte será para la distribución normal vendrá dada por: $L(\mu, \sigma^2) = -n \ln(\sqrt{2\pi}\sigma) - (1/2\sigma^2)\sum (x_i - \mu)^2 =$
 $-(n/2) \ln(2\pi\sigma^2) - (1/2\sigma^2)\sum (x_i - \mu)^2.$
- Así ahora derivamos la función soporte de la muestra e igualamos a cero para sacar cuales son los estimadores de máxima verosimilitud para μ, σ^2 de la población.

Estimadores de máxima verosimilitud: Ejemplo

- Así tenemos $L(\mu, \sigma^2) = -(n/2) \ln(2\pi\sigma^2) - (1/2\sigma^2) \sum (x_i - \mu)^2$ y la optimizamos en función de μ y σ^2 :
- $\partial L(\mu, \sigma^2) / \partial \mu = 0 = (2/2\sigma^2) \sum (x_i - \mu) = \sum (x_i - \mu) / \sigma^2 = (n\bar{x} - n\mu) / \sigma^2$, así $\hat{\mu} = \bar{x}$, por lo tanto parece lógico que el estimador máxima verosimilitud para la media de la normal es la media aritmética de la muestra observada.
- $\partial L(\mu, \sigma^2) / \partial \sigma^2 = 0 = -(n/2) (2\pi/2\pi\sigma^2) + (2 \sum (x_i - \mu)^2) / (2\sigma^2)^2 = -(n/2) (1/\sigma^2) + \sum (x_i - \mu)^2 / 2\sigma^4 = -(n\sigma^2/2\sigma^4) + \sum (x_i - \mu)^2 / 2\sigma^4 = (-n\sigma^2 + \sum (x_i - \mu)^2) / 2\sigma^4$ así despejando $\hat{\sigma}^2 = \sum (x_i - \mu)^2 / n = s^2$, por lo tanto parece lógico que el estimador máxima verosimilitud para la varianza de la normal es la desviación típica de la muestra observada.

Estimadores de máxima verosimilitud: propiedades de los estimadores máximo-verosímiles

- Si $\hat{\vartheta}_{MV}$ son los estimadores de máxima verosimilitud de un modelo de una población a través de sus muestras estos cumplen las siguientes propiedades:
 - Asintóticamente centrados.
 - Asintóticamente normales.
 - Asintóticamente eficientes.
 - Suficiencia.
 - Invariancia.
 - Robustez.

Estimadores de máxima verosimilitud: propiedades de los estimadores máximo-verosímiles - invariancia

➤ Invariancia:

- Si $\hat{\boldsymbol{\vartheta}}_{MV}$ es el estimador máximo verosímil de $\boldsymbol{\vartheta}$, entonces $h(\hat{\boldsymbol{\vartheta}}_{MV})$ es el estimador máximo verosímil de $h(\boldsymbol{\vartheta})$.
- Ejemplo:
 - Sea x_1, \dots, x_n una muestra aleatoria simple de $x \sim N(\mu, \sigma)$.
 - Sabemos que $\hat{\mu}_{MV} = \bar{x}$, lo hemos demostrado anteriormente.
 - ¿Quiénes serán los estimadores de máxima verosimilitud para 3μ , μ^2 y $1/\mu^2$?
 - Por el principio de invariancia tenemos que:
 - $\widehat{3\mu}_{MV} = 3\bar{x}$
 - $\widehat{\mu^2}_{MV} = \bar{x}^2$
 - $\widehat{1/\mu}_{MV} = 1/\bar{x}$

Estimadores de máxima verosimilitud: propiedades de los estimadores máximo-verosímiles – consistencia y centrado

➤ Consistencia:

➤ Bajo ciertas condiciones generales, $\hat{\vartheta}_{MV}$ es un estimador consistente de ϑ .

➤ $\lim_{n \rightarrow \infty} E[\hat{\vartheta}_n] \rightarrow \vartheta.$

➤ $\lim_{n \rightarrow \infty} Var[\hat{\vartheta}_n] \rightarrow 0.$

➤ Asintóticamente centrado:

➤ Se verifica que el $\lim_{n \rightarrow \infty} E[\hat{\vartheta}_{MV}] = \vartheta.$

Estimadores de máxima verosimilitud: propiedades de los estimadores máximo-verosímiles – normalidad asintótica

➤ Normalidad asintótica :

Recordad $f(a) + \frac{f'(a)}{1!}(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \frac{f^{(3)}(a)}{3!}(x-a)^3 + \dots$

- Para tamaños muestrales grandes, desarrollando en serie la función soporte en un entorno del estimador $\hat{\boldsymbol{\vartheta}}_{MV}$ para 2º orden:

Recordad que una normal es:
 $1/\sigma(2\pi)^{0.5} \exp\{-(1/2\sigma^2)(x-\mu)^2\}$

- $L(\boldsymbol{\vartheta}) \cong L(\hat{\boldsymbol{\vartheta}}_{MV}) + (1/2) \left(\frac{d^2 L[\hat{\boldsymbol{\vartheta}}_{MV}]}{d\boldsymbol{\vartheta}^2} \right) (\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}}_{MV})^2$.
- Si llamamos $\hat{\boldsymbol{\sigma}}_{MV}^2 = \left(-\frac{d^2 L[\hat{\boldsymbol{\vartheta}}_{MV}]}{d\boldsymbol{\vartheta}^2} \right)^{-1}$, entonces la verosimilitud se puede escribir:
 $\ell(\boldsymbol{\vartheta}) = \ell(\boldsymbol{\vartheta}|\mathbf{X}) = k \exp\left(-\frac{1}{2\hat{\boldsymbol{\sigma}}_{MV}^2} (\boldsymbol{\vartheta} - \hat{\boldsymbol{\vartheta}}_{MV})^2\right)$, como el soporte es el log de la verosimilitud, la verosimilitud es la exp, la constante k es $\exp(L(\hat{\boldsymbol{\vartheta}}_{MV}))$.
- Así la verosimilitud tiene la forma de una normal, con media $\hat{\boldsymbol{\vartheta}}_{MV}$, y varianza $\hat{\boldsymbol{\sigma}}_{MV}^2$.

Ejemplos para realizar en casa

- Realizar para casa los ejemplos del libro:
 - 7-1, 7-2, 7-3, 7-4, 7-6, 7-7, 7-8, 7-9, 7-10, 7-11 y 7-12.

Inferencia Estadística: Estimación por intervalos

Estimación por intervalos

- Introducción
- Un ejemplo simple
- El método del pivote
- Principales estadísticos pivote
- Estimación autosuficiente de intervalos de confianza (bootstrap)

Estimación por intervalos: introducción

- Ya sabemos cómo obtener **estimadores** para un parámetro y cómo calcular una **medida de la precisión del estimador**: es decir su desviación típica en el muestreo.
- Siempre es conveniente dar junto al estimador un intervalo de valores entre los cuales deberá estar el valor del parámetro que se estima con alta probabilidad.
- Éste es el objetivo de la **estimación por intervalos** de confianza.
- Para ilustrar el problema vamos a ver como ejemplo la estimación de la media con una muestra de tamaño 25 en una población normal de desviación típica conocida e igual a 10.
- Antes de observar la muestra y calcular el estimador, por ejemplo \bar{x} , se pueden predecir las discrepancias esperadas entre el estimador (\bar{x}) y el parámetro (μ): el 95% de las veces: $|\bar{x} - \mu| \leq 1,96 \frac{\sigma}{\sqrt{n}} = 1,96 \frac{10}{\sqrt{25}} = 3,92$

Estimación por intervalos: introducción

- Esto lo veremos en la metodología a continuación como se calcula con detalle.
- Pero lo importante es que podemos predecir que el 95% de las veces $|\bar{x} - \mu|$ no será mayor de 3,92 unidades.
- Por tanto si observamos $\bar{x} = 40$, podemos asegurar que μ estará previsiblemente en el intervalo $40 \pm 3,92$, el 95% de las veces que saquemos una muestra del mismo tamaño 25.
- **Ésta es la idea central de construcción de intervalos de confianza.**
- Así llamaremos intervalo de confianza para el parámetro ϑ a un nivel de confianza $(1 - \alpha)$, a una expresión del tipo $\vartheta_1 \leq \vartheta \leq \vartheta_2$ donde los límites ϑ_1 y ϑ_2 ($40 - 3,92$ y $40 + 3,92$ en el ejemplo) dependen de la muestra (a través de $\bar{x} = 40$), con $\alpha \leq 1$.

Estimación por intervalos: introducción

- Estos intervalos de confianza se calculan de manera tal que si tomamos muchas muestras, todas del mismo tamaño, y construimos un intervalo con cada muestra, podemos afirmar que el $100(1 - \alpha)\%$ (en el ejemplo 95%) de los intervalos así contruidos contendrán el verdadero valor del parámetro. En este caso en el ejemplo $\alpha = 0.05$.
- El otro $100\alpha \%$ (en el ejemplo 5%) de los intervalos así contruidos no contendrán el valor verdadero del parámetro.

Estimación por intervalos: introducción

- La idea general del procedimiento es que si estimamos ϑ con el estimador máximo verosímil $\hat{\vartheta}_{MV}$, el error relativo (error cometido/error promedio) de la estimación se define de la siguiente forma:
 - $\omega = \vartheta - \hat{\vartheta}_{MV}/\sigma(\hat{\vartheta}_{MV})$, donde $\sigma(\hat{\vartheta}_{MV})$ es la desviación típica asintótica de la distribución muestral del estadístico máximo-verosímil, que sigue asintóticamente una distribución normal estándar (por el TCL).

Estimación por intervalos: introducción

- Este resultado indica que, sea cual sea ϑ , podemos conocer aproximadamente la distribución del error relativo que cometeremos al estimar este parámetro por $\hat{\vartheta}_{MV}$.
- Esto nos lleva al **método del pivote** para la estimación de intervalos de confianza que veremos en detalle después.
- Pero antes vamos a ver este ejemplo sencillo con más profundidad para entender el problema de una manera más clara, y por tanto el método del pivote.

Estimación por intervalos: un ejemplo simple (para entender el problema)


- Vamos a tomar el ejemplo que acabamos de ver con más detalle:
 - Supongamos que sabemos que tenemos una variable aleatoria que sigue una distribución $N(\mu, \sigma)$ donde el valor de varianza es conocido $\sigma^2 = \sigma_0^2$.
 - El objetivo es, dada una m.a.s. de tamaño n de la variable obtener un intervalo a un nivel de confianza del 95 % para el parámetro μ de la distribución.
 - Así tenemos una probabilidad del 95% de encontrar μ en ese intervalo.
- Recordemos que al tomar una muestra de tamaño n de una variable con media μ y varianza σ^2 y distribución cualquiera (en particular una normal también), la distribución muestral de la media verifica que $E[\bar{x}] = \mu$ y $\text{Var}[\bar{x}] = \sigma^2/n$.
- En este caso la distribución muestral de la media muestral \bar{x} sigue una normal $N(\mu, \sigma_0/(n)^{0.5})$ ([transparencia 244](#)).
- Esto lo podemos aprovechar para construir el siguiente estadístico como variable aleatoria z que sigue una $N(0,1)$, que viene determinado por
 - $z = (\bar{x} - \mu)/(\sigma_0/\sqrt{n})$, que es la variable estandarizada.

Estimación por intervalos: un ejemplo simple (para entender el problema)

- Así la nueva variable aleatoria z se distribuye según una $N(0,1)$.
- Por favor notar que es importante que el nuevo estadístico tenga una distribución conocida, siendo esta distribución conocida independiente del parámetro que queremos estimar en este caso que es μ a través de la media muestral \bar{x} :
 - Ya que esto nos permite dada la nueva variable z construir una expresión del siguiente tipo (sabiendo que z es una normal):
 - $P(-z_{\alpha/2} \leq z \leq z_{\alpha/2}) =$
 $P(-z_{\alpha/2} \leq (\bar{x} - \mu)/(\sigma_0/\sqrt{n}) \leq z_{\alpha/2}) = 1 - \alpha$
 - Donde $z_{\alpha/2}$ es un valor de la normal estándar tal que cumple:
 - $P(z > z_{\alpha/2}) = 1 - \Phi(z_{\alpha/2}) = \alpha/2$, siendo Φ la función distribución normal.
- Esto nos permite estimar el parámetro μ a través de un intervalo de confianza de la siguiente manera.

Estimación por intervalos: un ejemplo simple (para entender el problema)

- Así la expresión anterior nos permite determinar, de manera independiente de μ , el valor $z_{\alpha/2}$ que delimita una probabilidad $(1-\alpha)$ dentro del intervalo centrado en cero $(-z_{\alpha/2}; z_{\alpha/2})$. Es decir $z_{\alpha/2} = z_{0.975}$
- En este caso, para la distribución $N(0, 1)$, y $(1-\alpha)=95\%$ y el valor $|z_{\alpha/2}|$ es aproximadamente 1,96 (mirar las tablas del final del libro, Tabla 4 Distribución normal estandarizada, $N(0,1)$).



Estimación por intervalos: un ejemplo simple (para entender el problema)

- Por lo tanto podemos poner para $\alpha=5\%$ según la figura anterior de la normal, teniendo en cuenta que 1.96 es el valor aproximado del punto percentil 97.5 de la distribución normal:
 - $P(-1.96 \leq (\bar{x} - \mu)/(\sigma_0/\sqrt{n}) \leq 1.96) = 0.95$
 - Tabla libro, pag 618, el área mas cercana es 0,97500 (que es el valor exacto que buscamos) que corresponde $z=1.96$ para el percentil $z_{0.975}$ de la normal.
- Así si despejamos μ obtenemos el intervalo de confianza siguiente:
 - $P(\bar{x} - 1.96 \frac{\sigma_0}{\sqrt{n}} \leq \mu \leq \bar{x} + 1.96 \frac{\sigma_0}{\sqrt{n}}) = 0.95$

Estimación por intervalos: un ejemplo simple (para entender el problema)

- Así la expresión $P(\bar{x} - 1.96 \frac{\sigma_0}{\sqrt{n}} \leq \mu \leq \bar{x} + 1.96 \frac{\sigma_0}{\sqrt{n}}) = 0.95$ lo que quiere decir básicamente es que:
- Para la **estimación de la media** con una **muestra de tamaño n** en una **población normal** de **desviación** típica conocida e igual a σ_0 .
 - **Podemos decir** que antes de observar la muestra y calcular el estimador, \bar{x} , se pueden predecir las **discrepancias** esperadas entre el estimador (\bar{x}) y el parámetro (μ) que vienen dadas por el siguiente intervalo de confianza el 95% de las veces que se observa la muestra:
 - $|\bar{x} - \mu| \leq 1,96 \frac{\sigma_0}{\sqrt{n}}$

Estimación por intervalos: método del pivote

- El método anterior se puede generalizar dando origen al conocido **método del pivote** para la construcción de intervalos de confianza.
- Así este se basa en la **elección de una variable aleatoria** que sea **función de la muestra** y del **parámetro a estimar**, con una serie de condiciones para la función:
 - Que sea una **función continua y monótona** del parámetro.
 - Que su **distribución sea conocida e independiente del parámetro a estimar**.

Estimación por intervalos: método del pivote

- Llamemos $g(\vartheta, X)$ a la variable escogida y que recibe el nombre de **estadístico pivote**.
- Vemos que esta variable depende del parámetro a estimar, ϑ , y la muestra escogida, X .
- Bajo estas condiciones, fijado el nivel de confianza $(1-\alpha)100\%$, siempre es posible encontrar los valores a y b tales que $P(a \leq g(\vartheta, X) \leq b) = (1-\alpha)$, siempre que la distribución sea conocida para la probabilidad, P , anterior.
- Por las condiciones exigidas sobre el estadístico, será posible despejar ϑ y por tanto obtener los límites para el intervalo.

Estimación por intervalos: método del pivote

- Recordemos que las condiciones que se exigen para el estadístico pivote son:
 1. Que sea una función continua y monótona del parámetro.
 2. Que su distribución sea conocida e independiente del parámetro a estimar.
- Debido a la primera condición podemos despejar el estimador para deducir el intervalo de confianza:
 - $P(g^{-1}(a, X) \leq \vartheta \leq g^{-1}(b, X)) = (1 - \alpha)$
- Siendo $\vartheta_1 = g^{-1}(a, X)$ y $\vartheta_2 = g^{-1}(b, X)$ los límites del intervalo deseado, para el estimador ϑ .

Estimación por intervalos: método del pivote

- Debido a la primera condición podemos asegurar que existen $g^{-1}(a, X)$ y $g^{-1}(b, X)$.
- Se puede demostrar que si una función f es continua y monótona en un intervalo $[a, b]$, entonces existe la inversa en el intervalo $[f(a), f(b)]$, y es también monótona y continua.
- Una función monótona es aquella que o bien es creciente o bien es decreciente.
- Debido a la segunda condición podemos calcular la confianza a través de la función de probabilidad (ya que la distribución es conocida):
 - $P(g^{-1}(a, X) \leq \vartheta \leq g^{-1}(b, X)) = (1 - \alpha)$

Estimación por intervalos: método del pivote

- Dado $P(a \leq g(\vartheta, X) \leq b) = (1 - \alpha)$, notar que **los valores a y b que la verifican en general no son únicos**.
- La elección se hace generalmente buscando que el **intervalo tenga la máxima precisión**, es decir, la longitud mínima que caiga la máxima densidad de probabilidad.
- Esta elección depende de la distribución del estadístico pivote.
- Para distribuciones simétricas y unimodales (distribución Normal o t de Student, por ejemplo) se consigue tomando el intervalo centrado, es decir, dejando una probabilidad de $\alpha/2$ a cada lado, como hemos visto en la figura anterior.

Estimación por intervalos: principales estadísticos pivote

➤ Intervalos para medias de poblaciones normales (varianza conocida de la población):

- Para poblaciones normales que se conoce la varianza, σ , ya sabemos cual es el estadístico pivote para el cálculo de intervalos de confianza para la media μ :

- $z = (\bar{x} - \mu)/(\sigma/\sqrt{n})$, en este caso z se distribuye como una $N(0,1)$.

- $P(-z_{\alpha/2} \leq z \leq z_{\alpha/2}) =$

$$P(-z_{\alpha/2} \leq (\bar{x} - \mu)/(\sigma/\sqrt{n}) \leq z_{\alpha/2}) = 1 - \alpha$$

- Donde el percentil $z_{\alpha/2}$ es un valor de la normal estándar tal que:
 - $P(z > z_{\alpha/2}) = 1 - \Phi(z_{\alpha/2}) = \alpha/2$, siendo Φ la función distribución normal.
 - Así los intervalos de confianza para μ a un nivel de confianza $(1 - \alpha)$ serán :
 - $\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$

Estimación por intervalos: principales estadísticos pivote

➤ Intervalos para medias de poblaciones normales (varianza conocida de la población):

- Recordar que los valores que se han escogido son simétricos para generar el intervalo más corto posible:
 - En el intervalo más corto posible que caiga la máxima densidad de probabilidad.
- Para la distribución de confianza despejamos de $z = (\bar{x} - \mu)/(\sigma/\sqrt{n})$, $\mu = \bar{x} + z(\sigma/\sqrt{n})$, así al variar α , como \bar{x} es constante, la única variable aleatoria es z .
- Así, la distribución generada es normal, con media \bar{x} y varianza σ/\sqrt{n} .
- Esta distribución resume la incertidumbre existente respecto al valor desconocido μ .

Estimación por intervalos: principales estadísticos pivote

- Cual es el mínimo tamaño de muestra necesario para obtener una precisión dada para estimar el la media en un intervalo de confianza dado. **Vamos a hacer un ejemplo.**
- Supongamos que la altura de los individuos de cierta población sigue una distribución $N(\mu, 7,5)$ estando las unidades en cm. Hallar el mínimo tamaño muestral necesario para estimar la altura media con un error inferior a 2 cm y con una confianza del 90%.
- Lo que queremos es que $|\bar{x} - \mu| < 2$ y como queremos una confianza del 90% entonces $z_{\alpha/2} = z_{0,05} = 1,645$ (tabla libro, pag 618, el área mas cercana está entre 0,94950 que corresponde a 1,64 y 0.95053 que corresponde a 1,65: así elegimos 1,645).
- Así sabemos que el intervalo de confianza de para la media de la altura viene determinado por:
$$\bar{x} - 1,645 \frac{7,5}{\sqrt{n}} \leq \mu \leq \bar{x} + 1,645 \frac{7,5}{\sqrt{n}}$$
 (el valor de 1,645 está calculado de manera más exacta).
- Una expresión equivalente es: $-1,645 \frac{7,5}{\sqrt{n}} \leq \bar{x} - \mu \leq 1,645 \frac{7,5}{\sqrt{n}}$
- O lo que es lo mismo: $|\bar{x} - \mu| \leq 1,645 \frac{7,5}{\sqrt{n}}$ (recordar que $|\bar{x} - \mu| < 2$, así $1,645 \frac{7,5}{\sqrt{n}}$ tiene que ser < 2)
- Sustituyendo por su valor $1,645 \frac{7,5}{\sqrt{n}} < 2$, y despejando n obtenemos $n > 38,05$
- Es decir con una muestra de $n=39$, el 90% de las veces el error en la estimación de la media de la altura para la población a través de la muestra es menor que 2 cm.

Estimación por intervalos: principales estadísticos pivote

- **Intervalos para medias de poblaciones normales (varianza desconocida de la población):**
 - Para este caso se utiliza una variable de Student para estimar el intervalo de confianza de μ : $t = (\bar{x} - \mu)/(\hat{s}/\sqrt{n})$ **con n-1 grados de libertad.**
 - Recordad que \hat{s} es el estimador varianza corregido para la muestra.
 - Además, el estadístico obtenido no depende de μ , y es función monótona de μ (esto es justo lo que necesitamos para el método del pivote), por lo tanto podemos decir que:
 - $P(-t_{\alpha/2} \leq t \leq t_{\alpha/2}) =$
$$P(-t_{\alpha/2} \leq (\bar{x} - \mu)/(\hat{s}/\sqrt{n}) \leq t_{\alpha/2}) = 1 - \alpha$$
 - Donde el percentil $t_{\alpha/2}$ es un valor de una t de Student tal que cumple:
 - $P(t > t_{\alpha/2}) = \alpha/2$, y por tanto el intervalo de confianza para μ a un nivel de confianza $(1 - \alpha)$ será:
 - $\bar{x} - t_{\alpha/2} \frac{\hat{s}}{\sqrt{n}} \leq \mu \leq \bar{x} + t_{\alpha/2} \frac{\hat{s}}{\sqrt{n}}$ (Ver ejemplo 8.2)

Estimación por intervalos: principales estadísticos pivote

- **Ejemplo (8-1):** En una empresa se anunció que los salarios el año pasado crecieron un promedio del 3,5%. Un grupo de trabajadoras toma una muestra de los incrementos que han recibido una muestra de 10 mujeres obteniendo los siguientes incrementos: 3%, 3%, 5%, 1%, 1%, 2%, 1%, 1,5%, 2%, 2%. Construir un intervalo de confianza para el incremento medio experimentado por la remuneración de las mujeres en esta empresa.
ESTE EJEMPLO ESTA MAL en el libro, la media y dispersión están mal calculadas.
- La media de los incrementos es $\bar{x} = 2,15$ y la desviación típica de los incrementos es $\hat{s} = 1,2483$ (desviación corregida, n-1).
- Para un intervalo de confianza del 95% se requiere el percentil de la distribución t de Student con 9 grados de libertad, $t_{0,975}$, que es 2,26 (tabla 5 del libro, pag 619).
- Por lo tanto el intervalo es $2,15 - 2,26 \frac{1,2483}{\sqrt{10}} \leq \mu \leq 2,15 + 2,26 \frac{1,2483}{\sqrt{10}}$
- Saliendo un intervalo de $1.2579 \leq \mu \leq 3.0421$, como este intervalo no incluye el 3,5% como valor posible, se puede concluir que existe una fuerte evidencia (al 95%) de que las mujeres han recibido un **incremento salarial menor que la media de los trabajadores.**

Estimación por intervalos: principales estadísticos pivote

- Intervalo para varianzas de poblaciones normales:
 - Para construir un intervalo de confianza para la estimación de la varianza de una población normal, tenemos en cuenta que
 - $\frac{ns^2}{\sigma^2} = \frac{(n-1)\hat{s}^2}{\sigma^2}$ se distribuye como χ_{n-1}^2 .
 - Por lo tanto, determinando dos valores χ_a^2 y χ_b^2 que dejen entre si $(1 - \alpha)$ de la distribución χ_{n-1}^2 ya lo tenemos:
 - $P(\chi_a^2 \leq \frac{ns^2}{\sigma^2} \leq \chi_b^2) = 1 - \alpha$, o expresado como $P(1/\chi_a^2 \geq \frac{\sigma^2}{ns^2} \geq 1/\chi_b^2) = 1 - \alpha$
 - Por tanto podemos encontrar el intervalo para estimar σ^2 a un nivel de confianza $(1 - \alpha)$ de la siguiente forma:
 - $ns^2/\chi_a^2 \geq \sigma^2 \geq ns^2/\chi_b^2$ o
 $(n-1)\hat{s}^2/\chi_a^2 \geq \sigma^2 \geq (n-1)\hat{s}^2/\chi_b^2$ (Ver ejemplo 8.2)
 - **Existen muchos más estadísticos pivote que pueden consultar en el capítulo 8 del libro.**